

Rapport des labs practice

Lab01

Pour chaque lab, la première étape consiste à lancer l'environnement de travail. Sachant que l'ensemble des dépendances (Python, Spark, environnement Conda, Jupyter Notebook) a déjà été installé et configuré lors du **Lab 0**

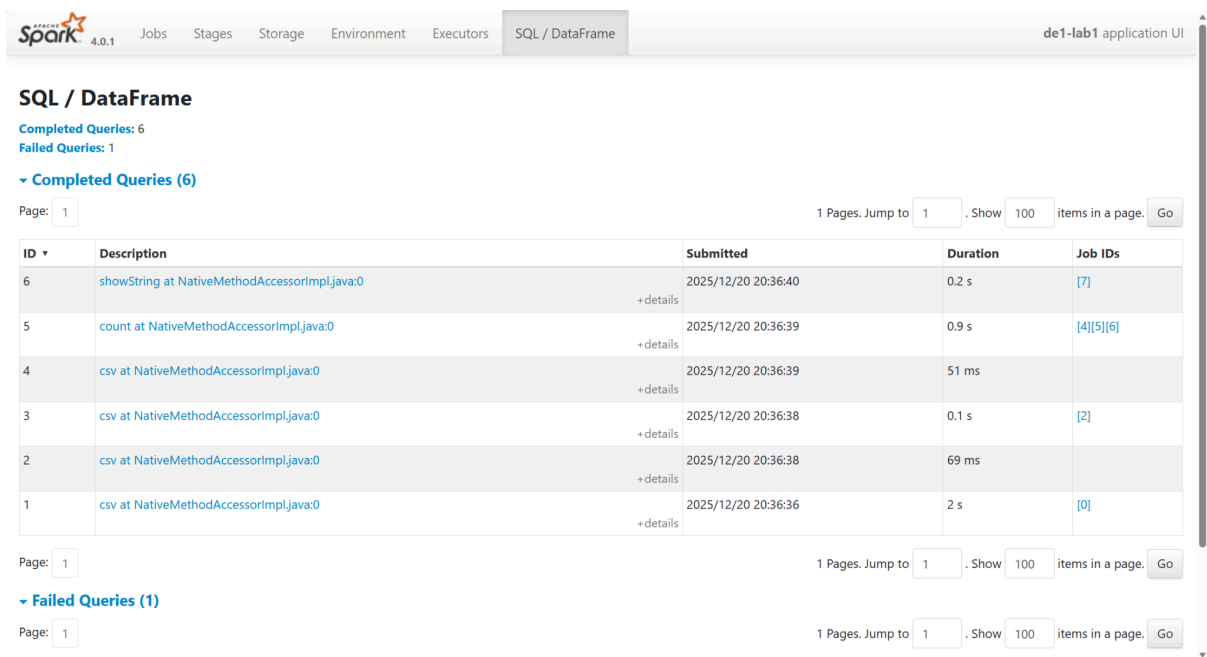
```
PROBLEMS OUTPUT DEBUG CONSOLE TERMINAL PORTS
(base) ranajabry@Rana:/mnt/c/Users/rana$ cd /mnt/c/Users/rana/OneDrive/Documents/Lab03
(base) ranajabry@Rana:/mnt/c/Users/rana/OneDrive/Documents/Lab03$ conda activate de1-env
(de1-env) ranajabry@Rana:/mnt/c/Users/rana/OneDrive/Documents/Lab03$ python --version
Python 3.10.19
(de1-env) ranajabry@Rana:/mnt/c/Users/rana/OneDrive/Documents/Lab03$ jupyter notebook
```

La capture d'écran ci-dessus illustre cette étape initiale, qui est commune à tous les labs et permet d'exécuter correctement l'ensemble des notebooks.

Dans la première partie du lab "**Import and Spark session**", aucune action particulière n'est requise. À ce stade, l'environnement est correctement configuré : la version de Python utilisée est **3.10.19** et la version de Spark est **4.0.1**

Dans l'interface Spark UI, section SQL / DataFrame, on observe la présence de plusieurs jobs identifiés par des IDs. Toutefois, à ce moment-là, aucune action significative n'a encore été déclenchée.

Dans la partie **Top-N with RDD API**, le code s'exécute sans erreur et produit les résultats attendus. Les jobs associés sont visibles dans Spark UI



SQL / DataFrame

Completed Queries: 6
Failed Queries: 1

▼ Completed Queries (6)

Page: 1 1 Pages. Jump to 1 . Show 100 items in a page. Go

ID	Description	Submitted	Duration	Job IDs
6	showString at NativeMethodAccessorImpl.java:0	2025/12/20 20:36:40	0.2 s	[7]
5	count at NativeMethodAccessorImpl.java:0	2025/12/20 20:36:39	0.9 s	[4][5][6]
4	csv at NativeMethodAccessorImpl.java:0	2025/12/20 20:36:39	51 ms	
3	csv at NativeMethodAccessorImpl.java:0	2025/12/20 20:36:38	0.1 s	[2]
2	csv at NativeMethodAccessorImpl.java:0	2025/12/20 20:36:38	69 ms	
1	csv at NativeMethodAccessorImpl.java:0	2025/12/20 20:36:36	2 s	[0]

Page: 1 1 Pages. Jump to 1 . Show 100 items in a page. Go

▼ Failed Queries (1)

Page: 1 1 Pages. Jump to 1 . Show 100 items in a page. Go

Afin de faciliter l'identification d'une exécution Spark SQL claire et isolée dans l'onglet SQL / DataFrame, nous avons volontairement ajouté une action explicite : `df.select("text").count()`

Cette instruction permet de forcer une exécution Spark SQL simple et facilement repérable dans Spark UI. La requête count apparaît clairement dans la liste des requêtes SQL (ID 7, Job associés [11][12])

Completed Queries (7)

Page: 11 Pages. Jump to 1. Show 100 items in a page. Go

ID	Description	Submitted	Duration	Job IDs
7	count at NativeMethodAccessorImpl.java:0	2025/12/20 21:01:10	0.2 s	[11][12]
6	showString at NativeMethodAccessorImpl.java:0	2025/12/20 20:36:40	0.2 s	[7]
5	count at NativeMethodAccessorImpl.java:0	2025/12/20 20:36:39	0.9 s	[4][5][6]
4	csv at NativeMethodAccessorImpl.java:0	2025/12/20 20:36:39	51 ms	
3	csv at NativeMethodAccessorImpl.java:0	2025/12/20 20:36:38	0.1 s	[2]
2	csv at NativeMethodAccessorImpl.java:0	2025/12/20 20:36:38	69 ms	
1	csv at NativeMethodAccessorImpl.java:0	2025/12/20 20:36:36	2 s	[0]

Page: 11 Pages. Jump to 1. Show 100 items in a page. Go

Exchange

shuffle records written: 2
remote merged reqs duration: 0 ms
remote merged blocks fetched: 0
records read: 2
local bytes read: 118.0 B
merged fetch fallback count: 0
local blocks read: 2
remote merged chunks fetched: 0
remote blocks read: 0
data size total (min, med, max)
32.0 B (16.0 B, 16.0 B, 16.0 B)
local merged bytes read: 0.0 B
local merged chunks fetched: 0
shuffle write time total (min, med, max)
4 ms (1 ms, 2 ms, 2 ms)
remote merged bytes read: 0.0 B
local merged blocks fetched: 0
corrupt merged block chunks: 0
fetch wait time: 0 ms
remote bytes read: 0.0 B
number of partitions: 1
remote reqs duration: 0 ms
remote bytes read to disk: 0.0 B
shuffle bytes written total (min, med, max)
118.0 B (59.0 B, 59.0 B, 59.0 B)

Duration: 0.2 s
Succeeded Jobs: 11 12

Les métriques sont présentes dans le nœud Exchange, notamment celles liées au shuffle et aux volumes de données traitées (Voir la capture d’écran ci-dessus). Ces informations ont ensuite été utilisées pour remplir la première ligne du fichier CSV des métriques correspondant à la partie **Top-N with RDD API**

Enfin, après cette étape, nous passons à l'analyse du **DataFrame plan**, en appliquant exactement la même logique. O

On obtient:

Duration: 2 s

Succeeded Jobs: 14 15

Dans la partie “**Projection experiment: select (*) vs minimal projection**”, l'objectif est de comparer l'impact de la projection des colonnes sur les performances d'exécution. Deux cas sont étudiés dans le même bloc de code.

Case A correspond à une projection complète, où toutes les colonnes sont sélectionnées (**select ***), avant d'appliquer une agrégation sur la catégorie.

Le Case B correspond à une projection minimale, où seules les colonnes strictement nécessaires à l'agrégation sont sélectionnées avant l'opération.

Lors de l'exécution de ce bloc, deux exécutions distinctes apparaissent dans la section **SQL / DataFrame** de Spark UI, chacune correspondant à l'un des deux cas.

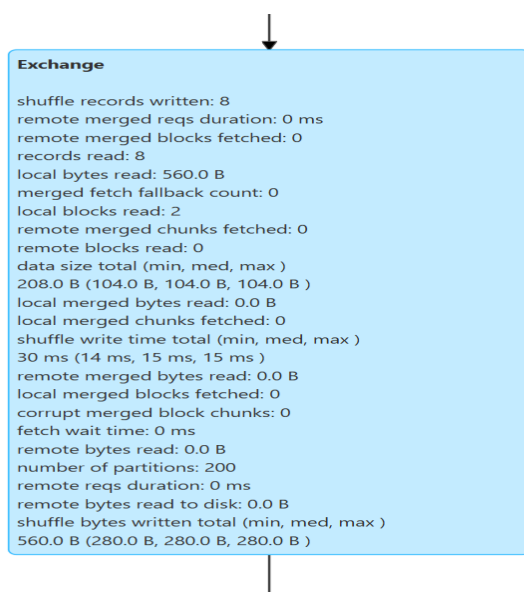
Page:

1 Pages. Jump to . Show items in a page.

ID ▾	Description	Submitted	Duration	Job IDs
11	count at NativeMethodAccessorImpl.java:0 <div>+ details</div>	2025/12/20 21:53:25	0.2 s	[21][22][23]
10	count at NativeMethodAccessorImpl.java:0 <div>+ details</div>	2025/12/20 21:53:25	0.4 s	[18][19][20]

Projection_all_cols: La durée d'exécution observée est de 0,4 secondes, et les jobs associés sont les jobs [18], [19] et [20].

Les métriques ont été collectées à partir du nœud **Exchange**



Duration: 0.4 s

Succeeded Jobs: 18 19 20

Projection_min: La durée d'exécution observée est de 0,2 secondes, et les jobs associés sont les jobs [21], [22] et [23].

Exchange

```

shuffle records written: 8
remote merged reqs duration: 0 ms
remote merged blocks fetched: 0
records read: 8
local bytes read: 560.0 B
merged fetch fallback count: 0
local blocks read: 2
remote merged chunks fetched: 0
remote blocks read: 0
data size total (min, med, max )
208.0 B (104.0 B, 104.0 B, 104.0 B )
local merged bytes read: 0.0 B
local merged chunks fetched: 0
shuffle write time total (min, med, max )
8 ms (3 ms, 4 ms, 4 ms )
remote merged bytes read: 0.0 B
local merged blocks fetched: 0
corrupt merged block chunks: 0
fetch wait time: 0 ms
remote bytes read: 0.0 B
number of partitions: 200
remote reqs duration: 0 ms
remote bytes read to disk: 0.0 B
shuffle bytes written total (min, med, max )
560.0 B (280.0 B, 280.0 B, 280.0 B )

```

Duration: 0.2 s

Succeeded Jobs: 21 22 23

Le tableau présenté ci-dessous récapitule l'ensemble des métriques collectées au cours de ce lab, pour les différentes expérimentations réalisées : **RDD API**, **DataFrame API**, **projection de toutes les colonnes** et **projection minimale**. Les valeurs reportées dans ce tableau proviennent directement des métriques observées dans Spark UI, notamment à partir des informations de durée d'exécution, du nœud Exchange.

C11

fx

	A	B	C	D	E	F	G	H
1	run_id	task	note	files_read	input_size_bytes	shuffle_read_bytes	shuffle_write_bytes	timestamp
2	r1	topN_rdd	RDD API	2	118	118	118	200 ms
3	r1	topN_df	DataFrame API	2	2969	2969	2969	2000 ms
4	r1	projection_all_cols	select_all	2	560	560	560	400 ms
5	r1	projection_min_cols	projection_minimal	2	560	560	560	200 ms
6								

Fin du Lab01

Lab02

Dans cette première section “**Ingest operational tables from CSV exports**”, nous avons chargé les tables opérationnelles à partir de fichiers CSV.

L'exécution des cellules a déclenché six jobs, correspondant aux différentes opérations de lecture et aux actions count utilisées pour valider les chargements.

▼ Completed Queries (6)

Page: 1 1 Pages. Jump to 1 . Show 100 items in a page. Go

ID ▼	Description	Submitted	Duration	Job IDs
6	count at NativeMethodAccessorImpl.java:0 + details	2025/12/21 18:38:17	0.1 s	[10] [11]
5	count at NativeMethodAccessorImpl.java:0 + details	2025/12/21 18:38:17	0.1 s	[8] [9]
4	count at NativeMethodAccessorImpl.java:0 + details	2025/12/21 18:38:16	0.1 s	[6] [7]
3	count at NativeMethodAccessorImpl.java:0 + details	2025/12/21 18:38:16	0.1 s	[4] [5]
2	count at NativeMethodAccessorImpl.java:0 + details	2025/12/21 18:38:16	0.2 s	[2] [3]
1	count at NativeMethodAccessorImpl.java:0 + details	2025/12/21 18:38:14	2 s	[0] [1]

Page: 1 1 Pages. Jump to 1 . Show 100 items in a page. Go

Exchange

shuffle records written: 1
remote merged reqs duration: 0 ms
remote merged blocks fetched: 0
records read: 1
local bytes read: 59.0 B
merged fetch fallback count: 0
local blocks read: 1
remote merged chunks fetched: 0
remote blocks read: 0
data size: 16.0 B
local merged bytes read: 0.0 B
local merged chunks fetched: 0
shuffle write time: 0 ms
remote merged bytes read: 0.0 B
local merged blocks fetched: 0
corrupt merged block chunks: 0
fetch wait time: 0 ms
remote bytes read: 0.0 B
number of partitions: 1
remote reqs duration: 0 ms
remote bytes read to disk: 0.0 B
shuffle bytes written: 59.0 B

Duration: 0.1 s

Succeeded Jobs: [10](#) [11](#)

La durée observée est de 0,1 secondes, avec les jobs associés [10] et [11].

Les métriques ont été relevées à partir du nœud Exchange et ont permis de remplir la ligne ingest_plan du fichier CSV des métriques.

Après cette section, une erreur est apparue lors de l'exécution du notebook.

Cette erreur était liée à une ambiguïté de colonnes après les jointures, due à la présence de colonnes portant le même nom dans plusieurs tables.

La correction consiste à effectuer un select explicite après les jointures, afin de conserver une seule version de chaque colonne et d'éliminer toute ambiguïté.

```

12 )
13 # Attach surrogate keys
14 df_fact = (df_fact
15     .withColumn("date_sk", sk(["date"]))
16     .withColumn("customer_sk", sk(["customer_id"]))
17     .withColumn("product_sk", sk(["product_id"]))
18     .withColumn("quantity", F.col("quantity").cast("int"))
19     .withColumn("unit_price", F.col("unit_price").cast("double"))
20     .withColumn("subtotal", F.col("quantity")*F.col("unit_price"))
21     .withColumn("year", F.year("date"))
22     .withColumn("month", F.month("date"))
23     .select("order_id", "date_sk", "customer_sk", "product_sk", "quantity", "unit_price", "subtotal", "year", "month")
24 )
25 df_fact.explain("formatted")
26 with open("proof/plan_fact_join.txt", "w") as f:
27     f.write(df_fact.queryPlan.toString())
28
File ~/miniconda3/envs/de1-env/lib/python3.10/site-packages/pyspark/sql/classic/dataframe.py:1623, in DataFrame.withColumn(self, colName, col)
1618 if not isinstance(col, Column):
1619     raise PySparkTypeError(
1620         errorClass="NOT_COLUMN",
1621         messageParameters={"arg_name": "col", "arg_type": type(col).__name__},
1622     )
-> 1623 return DataFrame(self._jdf.withColumn(colName, col._jc), self.sparkSession)

File ~/miniconda3/envs/de1-env/lib/python3.10/site-packages/py4j/java_gateway.py:1362, in JavaMember.__call__(self, *args)
1356 command = proto.CALL_COMMAND_NAME + \
1357     self.command_header + \
1358     args_command + \
1359     proto.END_COMMAND_PART
1361 answer = self.gateway_client.send_command(command)
-> 1362 return_value = get_return_value(
1363     answer, self.gateway_client, self.target_id, self.name)
1365 for temp_arg in temp_args:
1366     if hasattr(temp_arg, "_detach"):

```

La version corrigée est visible dans le notebook final (La correction a été proposée par Chatgpt)

Dans la partie **Fact Join**, nous avons ajouté une action explicite (count) après la sauvegarde du plan logique afin de déclencher une exécution Spark mesurable.

↓

```

Exchange

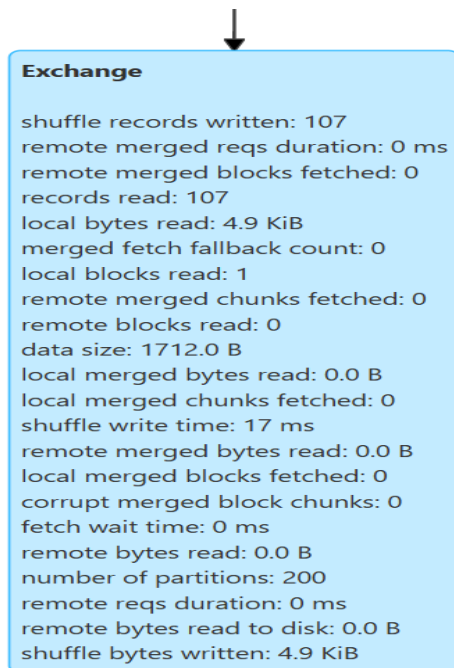
shuffle records written: 1
remote merged reqs duration: 0 ms
remote merged blocks fetched: 0
records read: 1
local bytes read: 59.0 B
merged fetch fallback count: 0
local blocks read: 1
remote merged chunks fetched: 0
remote blocks read: 0
data size: 16.0 B
local merged bytes read: 0.0 B
local merged chunks fetched: 0
shuffle write time: 1 ms
remote merged bytes read: 0.0 B
local merged blocks fetched: 0
corrupt merged block chunks: 0
fetch wait time: 0 ms
remote bytes read: 0.0 B
number of partitions: 1
remote reqs duration: 0 ms
remote bytes read to disk: 0.0 B
shuffle bytes written: 59.0 B

```

Duration: 0.5 s
Succeeded Jobs: 20 21 22 23 24

Pour cette section “Join then Project vs Project then Join”, les deux cas ont été exécutés dans des cellules séparées.

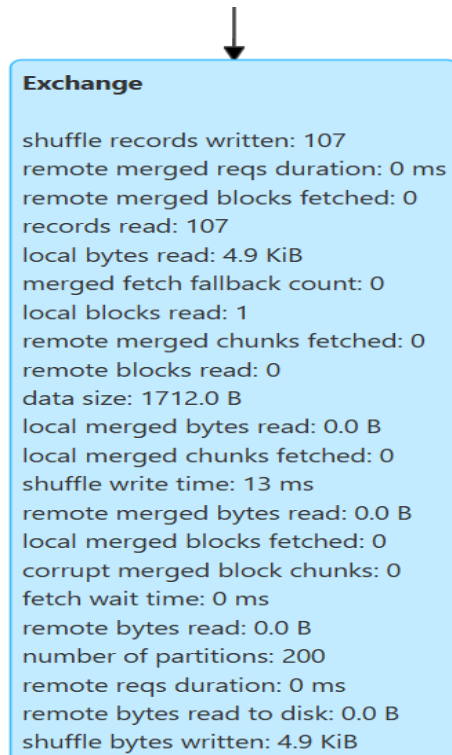
Case A — Join then Project



Duration: 0.4 s

Succeeded Jobs: [35](#) [36](#) [37](#) [38](#) [39](#)

Case B — Project then Join



Duration: 0.3 s

Succeeded Jobs: [40](#) [41](#) [42](#) [43](#) [44](#)

Le tableau présenté ci-dessous récapitule l'ensemble des métriques collectées au cours de ce lab

	A	B	C	D	E	F	G	H	I	J
1	run_id	task	note	files_read	input_size_bytes	shuffle_read_bytes	shuffle_write_bytes	timestamp		
2	r1	ingest_plan	csv_ingestion_with_structtype	6	59	0	59	100 ms		
3	r1	fact_join	df_fact.count() after join	1	59	0	59	500 ms		
4	r1	caseA_join_then_project	a.count()	107	4900	0	4900	400 ms		
5	r1	caseB_project_then_join	b.count()	107	4900	0	4900	300 ms		
6										
7										
8										

Fin du Lab02

Lab03

Pour la requête Q1 en représentation row, une action explicite (`q1_row.count()`) a été ajoutée après la génération du plan d'exécution. Cette action a déclenché une exécution Spark clairement identifiable dans Spark UI.

SQL / DataFrame

Completed Queries: 3

▼ Completed Queries (3)

Page: 1 1 Pages. Jump to 1 . Show 100 items in a page. Go

ID ▼	Description	Submitted	Duration	Job IDs
2	count at NativeMethodAccessorImpl.java:0 +details	2025/12/22 15:12:38	1 s	[4][5]
1	showString at NativeMethodAccessorImpl.java:0 +details	2025/12/22 15:12:05	0.2 s	[3]
0	count at NativeMethodAccessorImpl.java:0 +details	2025/12/22 15:12:03	2 s	[0][1][2]

Page: 1 1 Pages. Jump to 1 . Show 100 items in a page. Go

↓

Exchange

shuffle records written: 288
remote merged reqs duration: 0 ms
remote merged blocks fetched: 0
records read: 288
local bytes read: 28.4 KiB
merged fetch fallback count: 0
local blocks read: 3
remote merged chunks fetched: 0
remote blocks read: 0
data size total (min, med, max)
22.6 KiB (7.5 KiB, 7.5 KiB, 7.5 KiB)
local merged bytes read: 0.0 B
local merged chunks fetched: 0
shuffle write time total (min, med, max)
196 ms (62 ms, 64 ms, 69 ms)
remote merged bytes read: 0.0 B
local merged blocks fetched: 0
corrupt merged block chunks: 0
fetch wait time: 0 ms
remote bytes read: 0.0 B
number of partitions: 200
remote reqs duration: 0 ms
remote bytes read to disk: 0.0 B
shuffle bytes written total (min, med, max)
28.4 KiB (9.3 KiB, 9.4 KiB, 9.7 KiB)

Duration: 1 s
Succeeded Jobs: 4 5

Ces informations ont servi à remplir la ligne Q1 – row dans le fichier CSV des métriques.

On a exécuté la cellule d'après, et on a eu une erreur

```
Cell In[5], line 9
      3 (row_df
      4   .write.mode("overwrite")
      5   .partitionBy("year","month")
      6   .parquet(f"{col_base}/clicks_parquet"))
      7
      8 # Re-read columnar for fair comparison
----> 9 col_df = spark.read.schema(clicks_schema.add("year", "int").add("month", "int")).parquet(f"{col_base}/clicks_parquet")
     10 col_df.cache()
     11 print("Columnar rows:", col_df.count())

File ~/miniconda3/envs/de1-env/lib/python3.10/site-packages/pyspark/sql/types.py:1292, in StructType.add(self, field, data_type, nullable, metadata)
    1283     raise PySparkValueError(
    1284         errorClass="ARGUMENT_REQUIRED",
    1285         messageParameters={
    1286             (...),
    1287         },
    1288     )
    1289
    1290 if isinstance(data_type, str):
-> 1292     data_type_f = _parse_datatype_json_value(data_type)
    1293 else:
    1294     data_type_f = data_type

File ~/miniconda3/envs/de1-env/lib/python3.10/site-packages/pyspark/sql/types.py:2042, in _parse_datatype_json_value(json_value, fieldPath, collationsMap)
    2040     return VarcharType(int(m.group(1))) # type: ignore[union-attr]
    2041 else:
-> 2042     raise PySparkValueError(
    2043         errorClass="CANNOT_PARSE_DATATYPE",
    2044         messageParameters={"msg": str(json_value)},
    2045     )
    2046 else:
    2047     tpe = json_value["type"]

PySparkValueError: [CANNOT_PARSE_DATATYPE] Unable to parse datatype. int.
```

On a demandé à Chatgpt l'explication de cette erreur et il nous a proposé cette solution:

```
from pyspark.sql.types import IntegerType

col_base = "outputs/lab3/columnar"
# Write columnar
(row_df
 .write.mode("overwrite")
 .partitionBy("year", "month")
 .parquet(f"{col_base}/clicks_parquet"))

# Re-read columnar for fair comparison
col_df = (
    spark.read
    .schema(clicks_schema.add("year", IntegerType()).add("month", IntegerType()))
    .parquet(f"{col_base}/clicks_parquet")
)

col_df.cache()
print("Columnar rows:", col_df.count())
```

Columnar rows: 15000

Cette exécution a permis d'obtenir une nouvelle requête count visible dans Spark UI,

↓

Exchange
shuffle records written: 288
remote merged reqs duration: 0 ms
remote merged blocks fetched: 0
records read: 288
local bytes read: 28.4 KiB
merged fetch fallback count: 0
local blocks read: 3
remote merged chunks fetched: 0
remote blocks read: 0
data size total (min, med, max)
22.6 KiB (7.5 KiB, 7.5 KiB, 7.5 KiB)
local merged bytes read: 0.0 B
local merged chunks fetched: 0
shuffle write time total (min, med, max)
100 ms (28 ms, 33 ms, 38 ms)
remote merged bytes read: 0.0 B
local merged blocks fetched: 0
corrupt merged block chunks: 0
fetch wait time: 0 ms
remote bytes read: 0.0 B
number of partitions: 200
remote reqs duration: 0 ms
remote bytes read to disk: 0.0 B
shuffle bytes written total (min, med, max)
28.4 KiB (9.3 KiB, 9.4 KiB, 9.7 KiB)

↑

Duration: 0.4 s

Succeeded Jobs: 12 13

Pour les requêtes Q2 et Q3, la même logique a été appliquée, aussi bien pour la représentation row que column : chaque requête a été exécutée dans une cellule séparée, une action explicite (**count**) a été ajoutée afin de déclencher l'exécution Spark, les métriques ont été relevées à partir du nœud Exchange lorsque celui-ci était présent.

Q2_row

[plan_id=1066]

Exchange

shuffle records written: 6
remote merged reqs duration: 0 ms
remote merged blocks fetched: 0
records read: 6
local bytes read: 483.0 B
merged fetch fallback count: 0
local blocks read: 3
remote merged chunks fetched: 0
remote blocks read: 0
data size total (min, med, max)
264.0 B (88.0 B, 88.0 B, 88.0 B)
local merged bytes read: 0.0 B
local merged chunks fetched: 0
shuffle write time total (min, med, max)
27 ms (7 ms, 9 ms, 10 ms)
remote merged bytes read: 0.0 B
local merged blocks fetched: 0
corrupt merged block chunks: 0
fetch wait time: 0 ms
remote bytes read: 0.0 B
number of partitions: 200
remote reqs duration: 0 ms
remote bytes read to disk: 0.0 B
shuffle bytes written total (min, med, max)
483.0 B (159.0 B, 162.0 B, 162.0 B)

Duration: 0.7 s
Succeeded Jobs: 22 23 24

Q2_col

Exchange

shuffle records written: 6
remote merged reqs duration: 0 ms
remote merged blocks fetched: 0
records read: 6
local bytes read: 483.0 B
merged fetch fallback count: 0
local blocks read: 3
remote merged chunks fetched: 0
remote blocks read: 0
data size total (min, med, max)
264.0 B (88.0 B, 88.0 B, 88.0 B)
local merged bytes read: 0.0 B
local merged chunks fetched: 0
shuffle write time total (min, med, max)
38 ms (10 ms, 13 ms, 14 ms)
remote merged bytes read: 0.0 B
local merged blocks fetched: 0
corrupt merged block chunks: 0
fetch wait time: 0 ms
remote bytes read: 0.0 B
number of partitions: 200
remote reqs duration: 0 ms
remote bytes read to disk: 0.0 B
shuffle bytes written total (min, med, max)
483.0 B (159.0 B, 162.0 B, 162.0 B)

Duration: 0.3 s
Succeeded Jobs: 25 26 27

Q3_row

Exchange

shuffle records written: 288
remote merged reqs duration: 0 ms
remote merged blocks fetched: 0
records read: 288
local bytes read: 25.9 KiB
merged fetch fallback count: 0
local blocks read: 3
remote merged chunks fetched: 0
remote blocks read: 0
data size total (min, med, max)
18.1 KiB (6.0 KiB, 6.0 KiB, 6.0 KiB)
local merged bytes read: 0.0 B
local merged chunks fetched: 0
shuffle write time total (min, med, max)
33 ms (10 ms, 10 ms, 12 ms)
remote merged bytes read: 0.0 B
local merged blocks fetched: 0
corrupt merged block chunks: 0
fetch wait time: 0 ms
remote bytes read: 0.0 B
number of partitions: 200
remote reqs duration: 0 ms
remote bytes read to disk: 0.0 B
shuffle bytes written total (min, med, max)
25.9 KiB (8.6 KiB, 8.6 KiB, 8.7 KiB)

Duration: 0.4 s

Succeeded Jobs: 28 29

Q3_col

Exchange

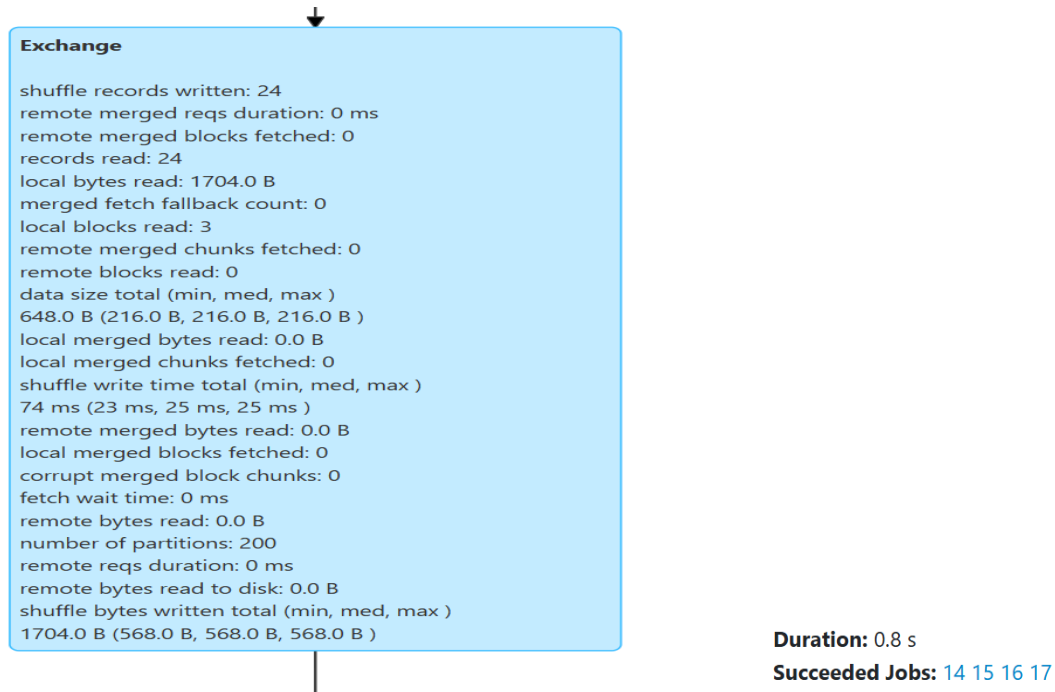
shuffle records written: 288
remote merged reqs duration: 0 ms
remote merged blocks fetched: 0
records read: 288
local bytes read: 25.9 KiB
merged fetch fallback count: 0
local blocks read: 3
remote merged chunks fetched: 0
remote blocks read: 0
data size total (min, med, max)
18.1 KiB (6.0 KiB, 6.0 KiB, 6.0 KiB)
local merged bytes read: 0.0 B
local merged chunks fetched: 0
shuffle write time total (min, med, max)
18 ms (5 ms, 5 ms, 7 ms)
remote merged bytes read: 0.0 B
local merged blocks fetched: 0
corrupt merged block chunks: 0
fetch wait time: 0 ms
remote bytes read: 0.0 B
number of partitions: 200
remote reqs duration: 0 ms
remote bytes read to disk: 0.0 B
shuffle bytes written total (min, med, max)
25.9 KiB (8.6 KiB, 8.6 KiB, 8.7 KiB)

Duration: 0.1 s

Succeeded Jobs: 30 31

Dans cette partie “**Join strategy: normal vs broadcast**” deux stratégies de jointure ont été comparées :

Jointure normale (j1) :



Jointure avec broadcast (j2) :

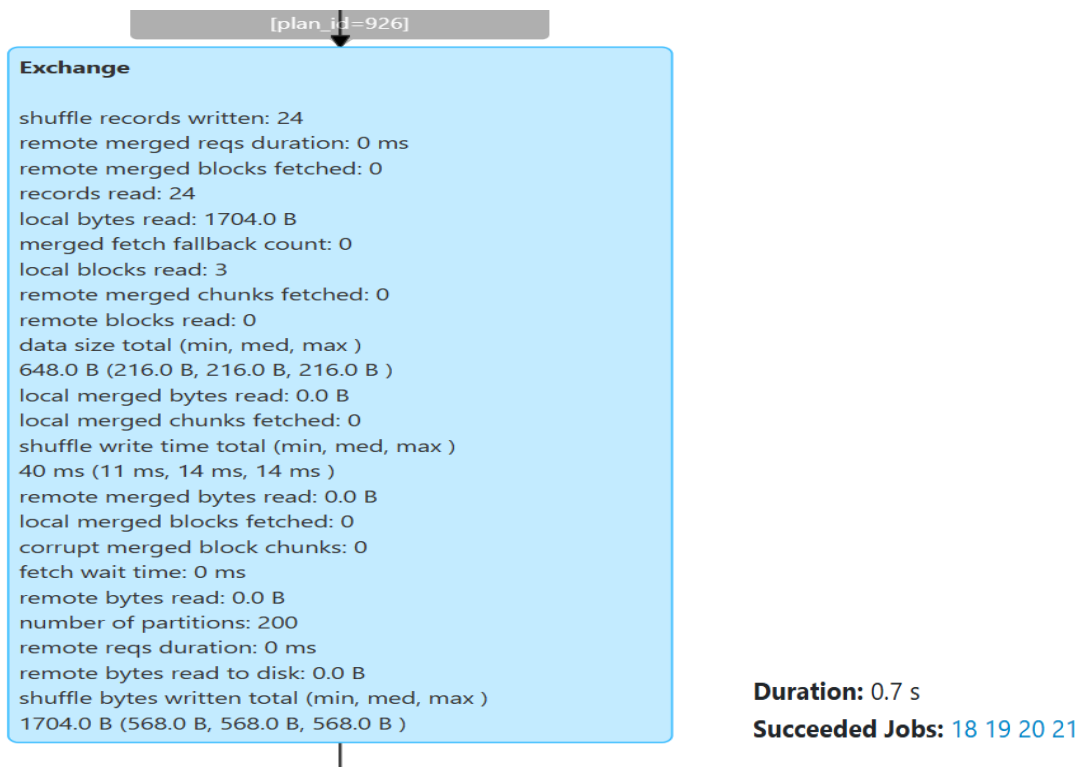


Tableau final :

H22										
	A	B	C	D	E	F	G	H	I	J
1	run_id	query	representation	files_read	input_size_bytes	shuffle_read_bytes	shuffle_write_bytes	notes	timestamp	
2	r1	Q1	row	3	28.4 KiB	0	28.4 KiB	count() after join	1000 ms	
3	r1	Q1	column	3	28.4 KiB	0	28.4 KiB	Q1 column count()	400 ms	
4	r1	Q2	row	3	483	0	483	Q2 row	700 ms	
5	r1	Q2	column	3	483	0	483	Q2 columns	300 ms	
6	r1	Q3	row	3	25.9 KiB	0	25.9 KiB	Q3 row	400 ms	
7	r1	Q3	column	3	25.9 KiB	0	25.9 KiB	Q3 column	ms	
8	r1	Join	normal	3	1704	0	1704	non broadcast join	800 ms	
9	r1	Join	broadcast	3	1704	0	1704	broadcast join	700 ms	
10										
11										
12										
13										

Fin du Lab03